Distributed file system

Modern data mining applications

Primjeri: Rangiranje web stranica po važnosti

Zajedničko: zahtjeva procesiranje velike količine podataka, podaci su često regularni, ideja je iskoristiti paralelnost

Datotečni sustav

Trajna pohrana podataka

Smješteni na vrhu niske fizičke pohrane

Organizirani u file-ove - .txt, podržava hijerarhijsku organizaciju

Putanja=relativni direktorij+ ime file-a

DirB/dirB/file.txt

Viša razina datotečnog sustava

Podržava pristup datotekama na udaljenim sustavima

Mora podržavati poklapanje?

Upravlja znatno većim količinama podataka nego OS

Pruža replikaciju/redundanciju podataka:

- Česti kvarovi
- Jeftini kompjuterski čvorovi
- Velika kolekcija čvorova

Većina obrade je napravljena na jednom „čvoru“

Paralellizam danas

- Rasprostranjenost Web-a
- Obrada je napravljena na instalacijama velikih količina jednostavnih kompjuterskih čvrova
- Tisuće čvorova koji rade nezavisno
- Troškovi su uvelik smanjeni u usporedbi s uporabom posebnih paralelnih računala

Paralelna računalna arhitektura – grupno računanje

8-64 računalnih čvorova unutar jednog „postolja.

Većinom su povezani sa gigabit eternetskim kablom

Komunikacija između postolja 1-10 Gbps – vrlo važno!

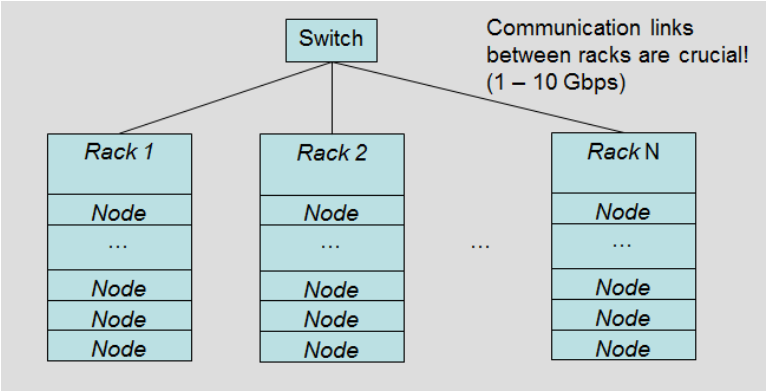

Problemi
Gubitak pojedinog čvora(zbog rušenja lokalnog diska)
Gubitak cijelog „postolja(rušenje mrežne veze)
Rješenje
Podaci se moraji spremati redundantno
Izračuna mora biti podijeljen na zadatke

DFS(large-scale fyle system organization)
Fajlovi su ogromne veličine
Rijetko su ažurirani, dodatni podaci su dodani fajlovima
Fajlovi su podijeljeni na komade(64 MB)
Komadi su replicirani na nekoliko čvorova koji su u odvojenim postljima
Za svaki fajl, postoji master čvor, sa svojom replikacijom

Primjeri DFS: Google file system, hadoop, cloudstore

Google file system

Dijeli mnoge zahtjeve sa drugim DFS

- Performanse
- Skalabilnost
- Dostupnost
- Pouzdanost

Pretpostavke dizajna
Visoka stopa urušavanja čvorova – velika kolekcija jeftinog i nepouzdanog hardvera
Umjeren broj izuzetno velikih fajlova – nekoliko milijuna fajlova, svaki 100 MB ili veći, uobičajeno gigabajti

Velik broj streaming čitanja, i mal broj random čitanja? What?

Dizajn odluke
Podaci su spremljeni u komade – 64MB
Pouzdanost se postiže replikacijom – svaki komad je na 3 servera
Jedan „vlasnik“ odgovoran za pristup i metapodatke
Nema „keširanja“ podataka
Poznato sučelje datotečnog sustava + Google API – podržava operacije create, delete, open, close, read, vrite
Custon google api uvodi snapshot i record append operacije

GFS ARHITEKTURA

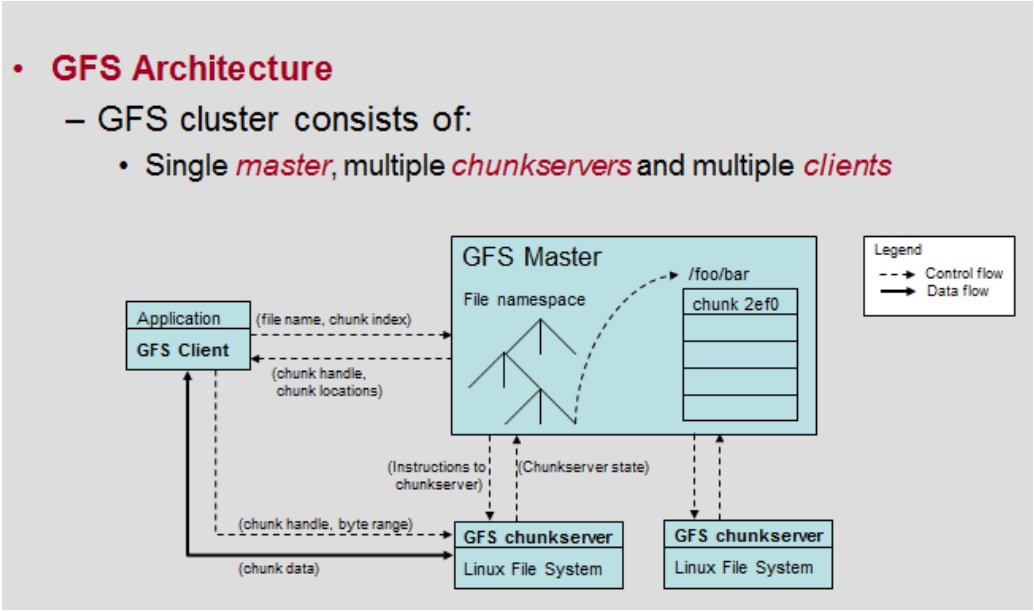

Veličina „komada“ je 64 MB

Prednosti

Reducira klijent-maser komunikaciju

Reducira mrežno opterećenje održavajući perzistentnu TCP vezu sa serverom tijekom dužeg razdoblja

Reducira veličinu metapodataka spremljenih na masteru

Nedostatci

Mal fajlvse sastoji od nekoliko komada(često 1)

Chunk serveri koji spremaju te podatke su potencijalno „usko grlo“

Metapodaci

Spremljeni na masteru

In-memory strukture podataka – 64 byte-a po komadu, brze operacije, jednostavnost performanse, fleksibilnost, pouzdanost

Checkpoint – b-stablo forma, može biti lako mapiran u memoriju, 1 minuta za napraviti potrebna, za nekoliko milijuna fajlova

Master operacije

Spremanje metapodataka

Upravljanje prostorom i zaključavanje

Periodička komunikacija sa chunk-serverima

Postavljanje replika

Kreiranje komada, re-replikacija, rebalansiranje

Skupljanje smeća

Detekcija starih replika

Mutacije

Zahtjevi Random zapisivanja ili dodavanja zapisa

Generalna ideja je smanjiti-minimizirati uključenost master čvora

Protok podataka je odvojen od kontrolnog protoka

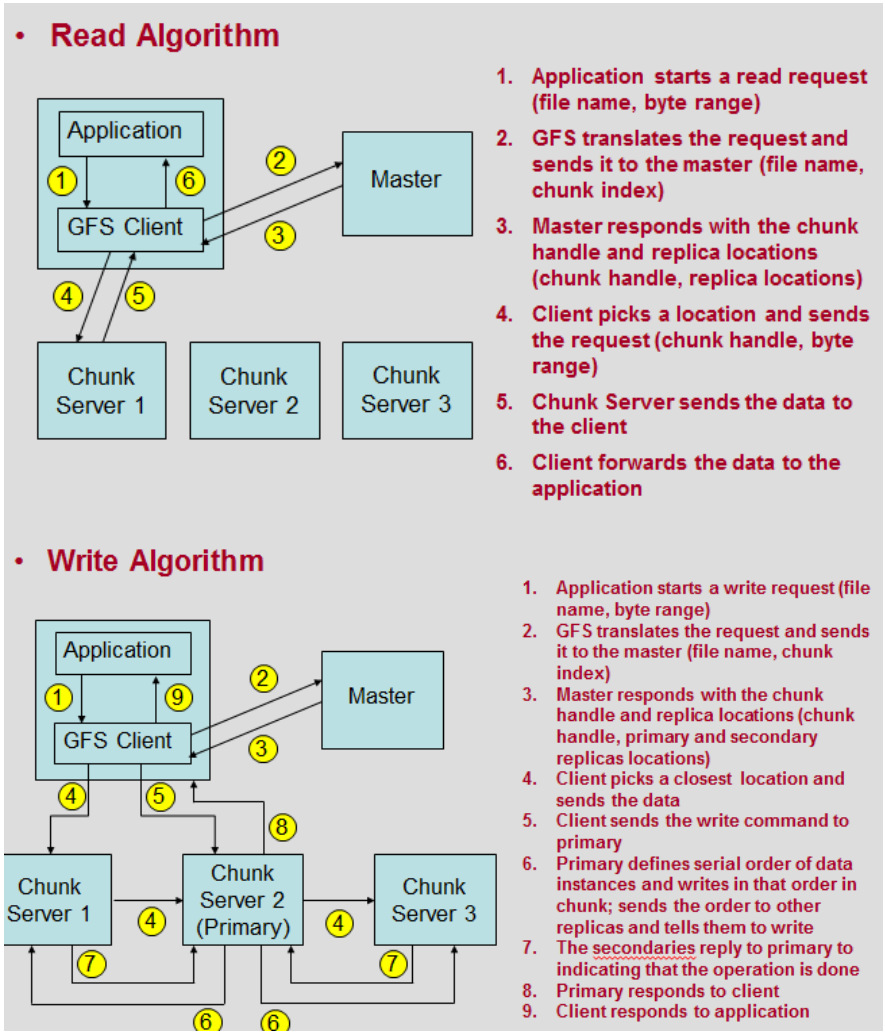

Atomic Record Append

GFS dodaje podatke u fajl atomički barem jednom

Klijent push-a upisane podatke na sve lokacije

Primarno se provjerava jel podatak odgovara određenom komadu podataka

Ako ne:

Postavlja chunk na maximalnu veličinu

Kaze drugom da isto to napravi

Informira klijenta da proba na sljedećem chunku

Ako da:

Dodaje podataka na taj chunk

Govori sekundarnom da napravi isto

Prima odgovor od sekundarnog i odgovara klijentu

Relaxed Consistency Model

Svi klijenti vide iste podatke neovisno iz koje replike čitaju – consistent region
Defined region – consistenti I klijenti vide što je mutacija upisala
Stanje određene regije ovisi o tipu mutacije I ako postoji konkurentnih mutacija ili ne

Zaključak

Postoji mnogo GFS clustera
Stotine/tisuće pohranjivanja na svakom čvoru
GFS podržava large-scale procesiranje

Hadoop file system

Namenodes I datanodes
Postoje: klijent, namenode(master), datanodes – pohranjuju I vraćaju blokove podataka, prijavljuju namenode-u koje sve blokove podataka sadrže

Razlike od GFS
Samo jedan zapis po fajlu
128 MB blok podataka
2 fajla po zapisu(data+checksum)
Nema record append operaciju
Hadoop je open source, omogućava mnoga sučelja i libraryje za raličite sustave